

# Shopping Mall AI

## LangChain LCEL & RAG 기반 지능형 쇼핑 챗봇 시스템

### 스마트한 정책 기반 자동 질의응답 솔루션

AS·결제·반품·배송·환불·회원 정책 문서를 벡터DB로 학습하여 고객 질문에 환각 없이 정확하게 답변하는 CS 운영 자동화 시스템

#### 프로젝트명

Shopping Mall AI Chatbot

#### 핵심 아키텍처

RAG + LangChain LCEL + 의도 분류

#### 기술 스택

Streamlit · LangChain · Gemini · Ollama · FAISS · SQLite

# 프로젝트 발표 목차

**PART I 프로젝트 개요 및 핵심 기능** | 문제 정의, 차별화 특징, 3대 주요 페이지 **P. 3**

**PART II 시스템 아키텍처 및 프로젝트 구조** | 데이터 파이프라인, 계층별 기술 스택, Vertical Slice 폴더 구조 **P. 4**

**PART III RAG 시스템 상세** | 문서 전처리 청킹, FAISS 벡터 색인화, 실시간 유사도 검색 **P. 5**

**PART IV LCEL 파이프라인 및 동적 라우팅** | 선언적 체인 구성, 질문 의도 감지 및 동적 프롬프트 매핑 **P. 6**

**PART V 품질 평가 및 향후 추진 과제** | 피드백 점수 체계, 대시보드 모니터링, API 전환, FAQ 자동화 **P. 7~8**

# I. 프로젝트 개요 및 핵심 기능

## I 1. 프로젝트 개요

Shopping Mall AI는 전자상거래 쇼핑몰의 **AS·결제·반품·배송·환불·회원 정책** 문서를 기반으로 고객 문의에 대해 **자동으로 신속·정확하게 답변**을 제공하는 지능형 **CS 어시스턴트**.

**RAG(검색 증강 생성)**를 통한 사내 규정 실시간 참조 및 **LCEL 체인** 기반 안정적인 응답 파이프라인 보장.

## I 2. 핵심 기술 차별화 요소

- **RAG 검색 증강**: FAISS 벡터 인덱스 기반 정밀한 규정 탐색
- **LCEL 파이프라인**: 간결한 선언적 체인 구성으로 확장성 극대화
- **의도 기반 자동 분류**: 문의 유형별 맞춤형 프롬프트 매핑
- **실시간 피드백 루프**: 사용자 평가(👍/😐/👎) 기반 체계적 품질 관리

## I 3. 3대 주요 페이지 구성 (UI)

### 💬 채팅 화면 (Chat Service)

RAG 기반 정책 근거 답변 생성 및 실시간 피드백 수집 지원.

### 📊 대시보드 (Analytics)

상담 통계 지표 시각화, 만족도 추이 및 세션 로그 실시간 조회.

### ⚙️ 관리자 설정 (Admin)

정책 파일 업로드 및 FAISS 벡터 인덱스 재생성 원클릭 관리.

## II. 시스템 아키텍처 및 프로젝트 구조

End-to-End 데이터 파이프라인 및 Vertical Slice 모듈 설계

### I 1. 데이터 처리 파이프라인

```
[고객 질문] → [의도 라우터] (AS/결제/배송/환불 등)
|
▼
[RAG 검색] → Ollama 768d & FAISS Top-K 추출
|
▼
[LCEL 체인] → Prompt | Gemini LLM | StrOutputParser
|
▼
[저장·응답] → SQLite 기록 + 화면 즉시 렌더링
```

### I 2. 계층별 기술 스택

| 계층      | 적용 기술           | 주요 역할                |
|---------|-----------------|----------------------|
| UI      | Streamlit       | 반응형 챗봇 및 통계 화면 시각화   |
| Logic   | LangChain LCEL  | 선언적 체인 파이프라인 조율      |
| AI Core | Gemini · Ollama | LLM 추론 및 768d 벡터 임베딩 |
| Storage | FAISS · SQLite3 | 벡터 인덱스 검색 및 세션 영속화   |

### I 3. Vertical Slice 프로젝트 구조

```
shopping_mall_ai/
├── app.py / config.py      # 진입점 및 환경설정
├── features/               # 기능별 독립 격리 폴더
│   ├── chat/              # 챗봇 서비스 및 UI
│   ├── dashboard/         # 통계 대시보드 UI
│   ├── settings/          # 정책 문서 인덱싱 관리
│   └── rag/               # Loader · Splitter · Retrieve
├── shared/                 # api.py (Gemini), db.py (SQLi
└── sample_data/ · data/   # 정책 문서 원본 및 faiss 색인
```

### I 4. 아키텍처 강점 및 핵심 파일

**기능별 수직 격리:** 각 기능(Chat, Dashboard, Settings)이 UI와 비즈니스 로직을 자체 보유하여 코드 변경 시 상호 간섭 완벽 차단.

| 핵심 모듈              | 역할 정의                   |
|--------------------|-------------------------|
| chatbot_service.py | 질문 의도 라우팅 및 LCEL 체인 실행  |
| retriever.py       | FAISS 인덱스 기반 최적 컨텍스트 검색 |

## III. RAG(검색 증강 생성) 시스템 상세

비정형 정책 문서 전처리 및 정확한 지식 기반 질의 매커니즘

### I 1. 문서 전처리 및 청킹 (Chunking)

#### Step 1. 문서 수집 & 분할

- DocumentLoader: AS·결제·반품·배송·환불·회원 정책 문서 로드
- RecursiveCharacterTextSplitter 활용 (500자 단위 분할)
- 문맥 단절 방지를 위해 인접 청크 간 100자 Overlap 유지

### I 2. 벡터 색인화 (FAISS)

#### Step 2. 인덱스 구축 및 영속화

- 768차원 고성능 임베딩 벡터 생성 (Ollama 연동)
- FAISS IndexFlatL2 정밀 탐색 인덱스 구축
- 런타임 성능을 위해 index.faiss 로컬 파일 자동 영속화

### I 3. 실시간 벡터 검색 (Retriever)

질의: "환불 요청 시 결제 수단별 취소 소요 기간은?"

|

- └─ 1. 질문 텍스트 768차원 임베딩 생성 (Ollama)
- └─ 2. FAISS Index L2 거리 기반 유사도 측정
- └─ 3. 연관도 최상위 문서 조항 추출 (k=10)

|

결과: [{ "content": "신용카드 취소 3~5일...", "score": 0.16 }]

### I 4. RAG 도입 핵심 효과

#### ✨ 도입 성과 및 안정성

- 환각 현상(Hallucination) 억제: 규정 문서 내 사실만 인용하여 응답.
- 지식 실시간 갱신: 모델 재학습 없이 문서 파일 교체 즉시 반영.
- 답변 근거 명시: 답변에 참조된 규정 출처 메타데이터 화면 제시.

## IV. LCEL 파이프라인 및 동적 라우팅

LangChain Expression Language를 통한 선언적 체인 설계

### I 1. 기존 방식 vs LCEL 방식 비교

```
# [기존 명령형 방식] - 절차 복잡, 예외 추적 곤란
prompt_text = template.format(context=ctx, question=q)
parsed_res = parser.parse(api.generate(prompt_text))

# [LCEL 선언형 방식] - 직관적 체이닝, 파이프라인 최적화
chain = prompt | llm | StrOutputParser()
response = chain.invoke({"context": docs, "question": q})
```

### I 3. 카테고리별 특화 프롬프트 전략

| 프롬프트 영역  | 전략 및 튜닝 방향                       |
|----------|----------------------------------|
| 배송·반품    | 출고 마감 시각, 지역별 추가 운임, 반품 가능 기한 집중 |
| 결제·환불    | 수단별 환불 소요 기간, 결제 오류 조치 규정 안내     |
| AS·회원·일반 | 무상 보증 조건, 회원 등급 혜택 안내 및 표준 CS 응대 |

### I 2. 질문 의도 자동 감지 (Routing)

고객 입력 질문 내 핵심 어휘를 실시간 감지하여 최적 프롬프트 분기:

- **배송/반품**: "배송", "출고", "송장", "반품", "교환" 키워드 감지
- **결제/환불**: "결제", "카드", "영수증", "환불", "취소" 키워드 감지
- **AS/회원/일반**: "수리", "보증", "탈퇴", "등급" 등 키워드 감지

### I 4. 런타임 체인 실행 흐름

User Query → Category Detector → FAISS Context → LCEL Chain Execution → Output Parsing → Streamlit Render

[파이프라인 단계별 개괄 설명]

- ① **질문 입력 & 의도 분류**: 사용자 질문 접수 즉시 키워드 기반 카테고리 판별
- ② **문맥 검색**: 감지된 유형에 맞춰 FAISS 벡터DB에서 핵심 정책 조항 추출
- ③ **체인 추론 & 렌더링**: 문맥과 질문을 결합한 프롬프트로 LLM 추론 후 화면 출력

## V. 품질 평가 및 대시보드 모니터링 시스템

실시간 피드백 루프와 데이터 기반 품질 관리 체계

### I 1. 사용자 피드백 평가 루프

고객 응답 직후 즉각적인 만족도 조사를 수행하여 정량적 평가 데이터 누적 수집.  
응답 품질을 상시 검증하고 부정확한 답변을 자동 선별하는 기반 마련.

### I 2. 피드백 점수 체계

| 평가 항목      | 의미 및 시스템 반영                   |
|------------|-------------------------------|
| 👍 만족 (+1)  | 정책 문서 내용과 정확히 부합하는 모범 답변      |
| 😐 보통 (0)   | 기본 내용은 맞으나 상세 설명이 일부 부족한 답변   |
| 👎 불만족 (-1) | 부정확한 응답 ➔ 관리자 감사 및 튜닝 대상으로 분류 |

### I 3. 대시보드 운영 모니터링

- **지표 시각화:** 일자별 상담 총량, 평균 만족도 평점 추이 차트 제공.
- **품질 역추적:** -1점 평가 질의의 질문/답변/참조 문서 정밀 감사.
- **데이터 관리:** 상담 이력 내보내기 및 불필요 세션 선별 정돈.

### I 4. 지속적 품질 개선 체계

**데이터 기반 순환 고도화:** 수집된 -1점 피드백 데이터를 분석하여 RAG 검색 청크 크기 최적화 및 카테고리별 특화 프롬프트 지속 보완.

지속적인 프롬프트 엔지니어링을 통해 미흡 응답 유형 재발 방지.

## V. 종합 평가 및 향후 추진 과제

아키텍처 고도화와 데이터 기반 지능형 FAQ 구축

### I 1. 프로젝트 종합 평가

RAG + LCEL 체인 + 의도 라우터의 결합을 통해 AS·결제·반품·배송·환불·회원  
전 영역 CS 문의에 대해 일관되고 정확한 자동 응답 시스템 성공적 구축.

기존 수작업 CS 업무 부담을 줄이고 정확한 정책 안내 체계 입증 완료.

### I 2. 아키텍처 항목별 평가

| 평가 영역          | 주요 평가 내용                   |
|----------------|----------------------------|
| Vertical Slice | 기능별 독립 모듈 격리 및 뛰어난 유지보수성   |
| LCEL 체인 구성     | 선언적 파이프라인 설계로 유지보수 및 확장 용이 |
| RAG 검색 정밀도     | FAISS 기반 정책 조항 매칭 및 환각 방지  |
| 피드백 루프         | 평가 점수 수집 및 관리자 역추적 체계 구축   |

### I 3. 향후 추진 과제

#### 과제 1. API 전환 및 React 프론트엔드 분리

- **FastAPI 백엔드 전환:** Streamlit 스크립트 재실행 구조를 탈피하여 고성능 비동기 REST API 서비스화.
- **React 챗봇 위젯 개발:** 쇼핑몰 웹 어디에나 탑재 가능한 플로팅 위젯 및 멀티 채널 확장성 확보.

#### 과제 2. 대화 데이터 기반 파인튜닝 & FAQ 구축

- **우수 상담 데이터 선별 저장:** 사용자 평가(👍) 검증 로그를 정제하여 도메인 파인튜닝 데이터셋 구축.
- **지능형 FAQ 자동 생성:** 축적 데이터를 분석하여 자주 묻는 질문(FAQ) 자동 추출 및 규정 최신화.